

Regresja i klasyfikacja

WSI – ćwiczenie 3

Autor: Kacper Skrodzki

Wstęp do eksperymentów

W ramach trzeciego ćwiczenia należało zaimplementować algorytm ID3 do generacji drzewa decyzyjnego o ograniczonej głębokości. Następnie należało stworzyć drzewo decyzyjne dla danego zestawu danych i przetestować jakość klasyfikatorów na nim. Dodatkowo w ramach części dla chętnych porównam sam algorytm ID3 z lasem losowym opartym na tym algorytmie.

Przebieg eksperymentów

Parametrem, który określi jakość klasyfikatorów będzie dokładność klasyfikacji, czyli ilość dobrych przypisów podzielona na wszystkie pary danych. Najpierw będzie testowany algorytm ID3 dla każdej głębokości – od 1 do 11, czyli wszystkie atrybuty będą rozpatrywane.

Aby można było wygenerować jakkolwiek drzewo decyzyjne trzeba odpowiednio przygotować dane. Najpierw należało zdyskredytować wartości ciągłe, takie jak wiek, wzrost, waga itp. Ponadto są wprowadzone zabezpieczenia, które mają ‘tatać’ wszystkie brakujące dane w zbiorze na podstawie średniej lub najczęściej występującej wartości.

Gdy zbiór jest w pełni i poprawnie uzupełniony jest on dzielony na trzy podzbiory:


- **Trenujący** – 70 % całości
- **Walidacyjny** – 15 % całości
- **Testowy** – 15 % całości

Na podstawie zbioru trenującego produkuje się drzewo decyzyjne, które jest następnie oceniane przez zbiór walidacyjny, a na końcu, jeśli wynik ze zbioru walidacyjnego jest satysfakcjonujący, ostatecznie przez zbiór testowy.


Adnotacja - wyniki dla poszczególnych głębokości to średnia uzyskanych wyników z pięciu różnych generacji drzew, gdzie zawartość zbioru trenującego, walidacyjnego i testowego jest losowo wybierana na podstawie następujących random seedów:

Random seedy - [38, 42, 46, 50, 54]

Średnia dokładność dla różnych głębokości



Średnia dokładność dla różnych głębokości



Na pierwszym wykresie możemy zauważyć, że dla niskich głębokości model jest bardzo niedotrenowany (underfitting) i często błędnie klasyfikuje. Natomiast dla dużych głębokości, bliskiej liczbie wszystkich atrybutów, model staje się za bardzo przeuczony (overfitting) co powoduje coraz to większy spadek dokładności przypisań.

Na drugim wykresie przybliżono okolice najlepszego średniego wyniku jaki uzyskano. Najlepsze wyniki wahają się między głębokością 6, głębokością 7.

Przybliżony średni wynik dla głębokości 6 oraz 7 dla zbioru testowego:

70.88 %

Wynik finalny tylko odrobinę różni się od średniego wyniku uzyskanego dla zbioru walidacyjnego dla tej samej głębokości, co nie zaburza poprawności testu.

Las losowy


Następnie w kolejności został przetestowany las losowy bazujący na obecnym algorytmie ID3. Testy zostały przeprowadzone na różnej liczebności lasu:

Wielkości lasu: [200, 400, 600, 800, 1000, 1200, 1400]


Adnotacja - wyniki dla poszczególnych liczebności lasu to też średnia uzyskanych wyników z pięciu różnych generacji lasów losowych, gdzie zawartość zbioru trenującego, walidacyjnego i testowego jest losowo wybierana na podstawie następujących random seedów:

Random seedy - [38, 42, 46, 50, 54]

Średnia dokładność dla różnych lasów losowych



Średnia dokładność dla różnych lasów losowych



Na powyższych wykresach przedstawiono średnie wyniki dokładności dla lasów o różnej liczbie testowanych już na zbiorze walidacyjnym. Na drugim wykresie ukazano przybliżenie na okolice najlepszego wyniku, który osiągnięto dla lasu o **400 drzewach**. Jednakże należy zwrócić uwagę na to, że wyniki dla różnych liczebności lasów losowych są bardzo do siebie podobne. Wynika z tego, że las losowy oparty na ID3 nie potrzebuje wielu drzew, aby był bardzo dokładny.

Ogólnie najlepszy wynik uzyskany po testowaniu na podzbiorze testowym wynosi:

68.29 %

Tak jak w przypadku samego ID3, wynik z walidacji i wynik z testu różni się lekko, ale ta różnica nie wpływa na wiarygodność uzyskanych dokładności.

Podsumowanie wyników

Z przetestowania lasu losowego i czystego algorytmu ID3 do klasyfikacji wynika jasno, że oba podejścia dają zbliżony wynik. Jednakże podejście z lasem losowym pozwala na łatwiejszą modyfikację tworzenia drzew oraz przeciwdziała overfitting-owi modelu.

Co do zbioru danych, z którego model korzysta można stwierdzić, że jakość klasyfikatorów jest całkiem dobra, lecz nie idealna. Dodatkowo, gdzie nie gdzie pojawiały się anomalie w atrybutach, które trzeba było odpowiednio unormalizować.