

Zagadnienie przeszukiwania i podstawowe podejście do niego

WSI – ćwiczenie 4

Autor: Kacper Skrodzki

Wstęp do eksperymentów

W ramach czwartego ćwiczenia należało zaimplementować algorytm gradientu prostego do znalezienia minimum funkcji Ackleya jedno oraz dwu wymiarowej. Następnie należało przeanalizować wpływ rozmiaru kroku na działanie algorytmu.

Eksperymenty – gradient prosty

Zanim jednak przedstawię wyniki uzyskane z eksperymentów, należy omówić hiperparametry użyte w eksperymentach. Są to:

- **Maksymalna liczba iteracji** = 1000
- **Zakres tolerancji** = $1e-8$
- **Punkt startowy** – 5.0 oraz (5.0, 5.0)
- **Skoki** = [0.001, 0.01, 0.03, 0.05, 0.07, 0.1, 0.15, 0.2, 0.5]

Maksymalna liczba iteracji ma za zadanie ustawić limit czasowy poszukiwań minimum. W przeciwnym przypadku algorytm działałby w nieskończoność oraz jego poszukiwania mogłyby się wykoleić.


Zakres tolerancji pełni funkcję drugiego warunku czasowego. W momencie, kiedy przeszukiwanie utknie w jakimś minimum lokalnym bez możliwości pokonania siodła albo kiedy zostanie osiągnięta bliska okolica minimum globalnego, zakres tolerancji zostanie osiągnięty i algorytm przestanie działać i zwróci obecny wynik przeszukiwań. Ma to na celu oszczędzenie czasu przeszukiwań oraz zagwarantowaniu nie wypadnięcia z minimum globalnego.

Punkt startowy jest miejscem, z którego zaczynamy przeszukiwanie funkcji. Jego położenie wpływa nieco na algorytm, gdyż może się on obecnie znajdować w siodle.


Skoki są integralną częścią algorytmu gradientu prostego. Odpowiednio wybrany skok pozwala na stabilność algorytmu, możliwość pokonywania siodła oraz relatywnie szybki czas przeszukiwania. Natomiast źle dobrana wartość skoku może prowadzić do zbyt dużych oscylacji albo niemożności pokonania siodła.

Wyniki eksperymentów dla jednowymiarowej funkcji Ackleya


SKOK	X	f(x)	ITERACJE
0.001	4.987122	12.632316	109
0.01	4.986228	12.632269	7
0.03	5.103869	13.298645	1000
0.05	4.999043	12.641051	1000
0.07	-0.161228	1.655167	1000
0.1	-1.436550	7.314809	1000
0.15	74.995593	20.001036	1000
0.2	-0.478972	4.174166	1000
0.5	-32.556137	22.297309	1000




Rysunek 1 - przykład niemożności wyjścia z minimum lokalnego



Rysunek 2 - przykład gradientu prostego z dobrym skokiem



Rysunek 3 - przykład co się dzieje jak jest zbyt duży skok



Rysunek 4 - analiza anomalii

Wnioski:

Tak jak było to omówione wcześniej, odpowiednia wartość skoku znacząco wpływa na wynik przeszukiwania. Dla bardzo małych wartości: 0.001 - 0.05 algorytm zatrzymuje się blisko punktów startowych (rys. 1), nie mogąc pokonać siodła. Dla wartości z przedziału 0.07 - 0.1 (rys. 2) uzyskujemy już bardzo dobre wyniki, bliskie minimum globalnego. Natomiast wartości ponad 0.1 w większości przynoszą mierne rezultaty, gdyż duża wartość skoku prowadzi do coraz to większych przestrzeleń.

Jednakże można zaobserwować ciekawą sytuację dla wartości 0.15 oraz 0.2 (rys. 3 i 4). W przypadku tej pierwszej widzimy ogromne oddalenie od minimum globalnego. Natomiast dla wartości 0.2 uzyskujemy bardzo dobry wynik jak z przedziału 0.07 - 0.1.


Z czego to wynika? Anomalia ta ma związek z rozkładem wartości funkcji Ackleya. Sama funkcja posiada liczne 'górki sinusowe', czyli silne oscylacje gradientowe, które można pozwalać na przekroczenie wielu siodła naraz przy dużym kroku. Ponadto wartości funkcji wraz z oddalaniem się od $x=0$ są relatywnie małe i podobne. To może doprowadzić do sytuacji, gdzie jak raz algorytm zawędruje za daleko od centrum układu, to już z powrotem nie powróci do niego, gdyż ma 'wrażenie' bliskości minimum.

Przez te dwie właściwości, skoki o wartościach większych od 0.1 mogą dać dobry wynik, gdyż akurat się 'wstrzeliły', gdzie reszta wartości zawędrowała daleko od centrum.


Wyniki eksperymentów dla dwuwymiarowej funkcji Ackleya

SKOK	(X,Y)	f(X, Y)	ITERACJE
------	-------	---------	----------


0.001	(4.991545, 4.991545)	12.633791	207
0.01	(4.990362, 4.990362)	12.633193	20
0.03	(4.990229, 4.990229)	12.633135	31
0.05	(5.074208, 5.074208)	13.026021	1000
0.07	(4.973870, 4.973870)	12.640168	1000
0.1	(5.205043, 5.205043)	14.334857	1000
0.15	(-0.037780, -0.037780)	0.225720	1000
0.2	(0.023858, 0.023858)	0.125521	1000
0.5	(28.135549, 28.135549)	20.713983	1000



Rysunek 5 - przykład złej wartości skoku



Rysunek 6 - przykład dobrej wartości skoku



Rysunek 7 - przykład, co się dzieje dla zbyt dużego skoku (wyjście poza podany zakres)

Wnioski:

Podobnie jak w przypadku jednowymiarowej funkcji Ackleya tutaj też zauważamy wagę znaczenia wartości skoku. Jedyną różnicą jaką występuję względem przypadku 1D to to, że najlepsze wartości znajdują się w przedziale 0.15 - 0.2 (rys.6), gdzie od 0.001 - 0.1 algorytm nie może przeskoczyć siodła (rys.5), a od wartości 0.5 jest już wędrowanie (rys.7). Te przesunięcie w wartościach wynika z samych właściwości dwuwymiarowej funkcji Ackleya.

Podsumowanie

Jak możemy zauważyć, algorytm gradientu prostego jest bardzo wrażliwy na wartość skoku. Zbyt mała wartość spowoduje utknięcie algorytmu w punkcie startowym.

Natomiast zbyt duża wartość spowoduje wędrowanie algorytmu po funkcji i zagnieżdżenia się w minimum lokalnym bez możliwości wyjścia z niego.