

Zagadnienie przeszukiwania i podstawowe podejście do niego

WSI – ćwiczenie 4

Autor: Kacper Skrodzki

Wstęp do eksperymentów

W ramach czwartego ćwiczenia należało zaimplementować algorytm gradientu prostego do znalezienia minimum funkcji Ackleya jedno oraz dwu wymiarowej. Następnie należało przeanalizować wpływ rozmiaru kroku na działanie algorytmu.

Dodatkowo można było zaimplementować wersję algorytmu prostego z momentum (SGD + Momentum) i też je przeanalizować pod względem rozmiaru skoku.

Eksperymenty – gradient prosty

Zanim jednak przedstawię wyniki uzyskane z eksperymentów, należy omówić hiperparametry użyte w eksperymentach. Są to:

- **Maksymalna liczba iteracji** = 1000
- **Zakres tolerancji** = $1e-8$
- **Punkt startowy** – 5.0 oraz (5.0, 5.0)
- **Skoki** = [0.001, 0.01, 0.03, 0.05, 0.07, 0.1, 0.15, 0.2, 0.5]

Maksymalna liczba iteracji ma za zadanie ustawić limit czasowy poszukiwań minimum. W przeciwnym przypadku algorytm działałby w nieskończoność oraz jego poszukiwania mogłyby się wykoleić.

Zakres tolerancji pełni funkcję drugiego warunku czasowego. W momencie, kiedy przeszukiwanie utknie w jakimś minimum lokalnym bez możliwości pokonania siodła albo kiedy zostanie osiągnięta bliska okolica minimum globalnego, zakres tolerancji zostanie osiągnięty i algorytm przestanie działać i zwróci obecny wynik przeszukiwań. Ma to na celu oszczędzenie czasu przeszukiwań oraz zagwarantowaniu nie wypadnięcia z minimum globalnego.

Punkt startowy jest miejscem, z którego zaczynamy przeszukiwanie funkcji. Jego położenie wpływa nieco na algorytm, gdyż może się on obecnie znajdować w siodle.

Skoki są integralną częścią algorytmu gradientu prostego. Odpowiednio wybrany skok pozwala na stabilność algorytmu, możliwość pokonywania siodła oraz relatywnie szybki czas przeszukiwania. Natomiast źle dobrana wartość skoku może prowadzić do zbyt dużych oscylacji albo niemożności pokonania siodła.

Wyniki eksperymentów dla jednowymiarowej funkcji Ackleya

SKOK	X	F(X)	ITERACJE
0.001	4.987122	12.632316	109
0.01	4.986228	12.632269	7
0.03	5.103869	13.298645	1000
0.05	4.999043	12.641051	1000
0.07	-0.161228	1.655167	1000
0.1	-1.436550	7.314809	1000
0.15	74.995593	20.001036	1000
0.2	-0.478972	4.174166	1000
0.5	-32.556137	22.297309	1000

Wnioski:

Tak jak było to omówione wcześniej, odpowiednia wartość skoku znacząco wpływa na wynik przeszukiwania. Dla bardzo małych wartości: 0.001 - 0.05 algorytm zatrzymuje się blisko punktów startowych, nie mogąc pokonać siodła. Dla wartości z przedziału 0.07 - 0.1 uzyskujemy już bardzo dobre wyniki, bliskie minimum globalnego. Natomiast wartości ponad 0.1 w większości przynoszą mierne rezultaty, gdyż duża wartość skoku prowadzi do coraz to większych przestrzeleni.

Jednakże można zaobserwować ciekawą sytuację dla wartości 0.15 oraz 0.2. W przypadku tej pierwszej widzimy ogromne oddalenie od minimum globalnego. Natomiast dla wartości 0.2 uzyskujemy bardzo dobry wynik jak z przedziału 0.07 - 0.1.

Z czego to wynika? Anomalia ta ma związek z rozkładem wartości funkcji Ackleya. Sama funkcja posiada liczne 'górki sinusowe', czyli silne oscylacje gradientowe, które można pozwalać na przekroczenie wielu siodła naraz przy dużym kroku. Ponadto wartości funkcji wraz z oddalaniem się od $x=0$ są relatywnie małe i podobne. To może doprowadzić do sytuacji, gdzie jak raz algorytm zawędruje za daleko od centrum układu, to już z powrotem nie powróci do niego, gdyż ma 'wrażenie' bliskości minimum.

Przez te dwie właściwości, skoki o wartościach większych od 0.1 mogą dać dobry wynik, gdyż akurat się ‘wstrzeliły’, gdzie reszta wartości zawędrowała daleko od centrum.

Wyniki eksperymentów dla dwuwymiarowej funkcji Ackleya

SKOK	(X,Y)	F(X, Y)	ITERACJE
0.001	(4.991545, 4.991545)	12.633791	207
0.01	(4.990362, 4.990362)	12.633193	20
0.03	(4.990229, 4.990229)	12.633135	31
0.05	(5.074208, 5.074208)	13.026021	1000
0.07	(4.973870, 4.973870)	12.640168	1000
0.1	(5.205043, 5.205043)	14.334857	1000
0.15	(-0.037780, -0.037780)	0.225720	1000
0.2	(0.023858, 0.023858)	0.125521	1000
0.5	(28.135549, 28.135549)	20.713983	1000

Wnioski:

Podobnie jak w przypadku jednowymiarowej funkcji Ackleya tutaj też zauważamy wagę znaczenia wartości skoku. Jedyna różnica jaka występuje względem przypadku 1D to to, że najlepsze wartości znajdują się w przedziale 0.15 - 0.2, gdzie od 0.001 - 0.1 algorytm nie może przeskoczyć siodeł, a od wartości 0.5 jest już wędrowanie. Te przesunięcie w wartościach wynika z samych właściwości dwuwymiarowej funkcji Ackleya.

Eksperymenty – SGD + Momentum

Stochastyczny gradient prosty z momentum korzysta z losowego szumu, aby móc wprowadzić stochastyczny element do algorytmu. W związku z tym, część wyników które będą przedstawione w następujących tabelach będą średnią wartością dla pięciu random seedów. Poza tym, reszta hiper parametrów pozostaje bez zmian.

Random seed-y: [30, 40, 50, 60, 70]

Wyniki eksperymentów dla jednowymiarowej funkcji Ackleya; SGD + Momentum

SKOK	X	F(X)	ITERACJE
0.001	4.984072	12.632503	11
0.01	4.986389	12.632271	41
0.03	4.985389	12.632302	49
0.05	-2.229859	8.779721	1000
0.07	-0.036446	0.215298	1000
0.1	-76.603604	22.266922	1000
0.15	-145.848651	20.930620	1000
0.2	-247.198405	21.343173	1000
0.5	-6695.879108	20.653300	1000

SKOK	Avg X	Avg F(X)
0.001	4.984584440478821	12.632461305111274
0.01	4.985963449899001	12.632298432107518
0.03	4.987766090382763	12.632856493515892
0.05	-3.7412275419692884	7.455199931403437
0.07	10.603585397237682	7.575655141913887
0.1	-3.2857492160789867	16.353582187536023
0.15	-35.279672425383296	19.997769403545767
0.2	-17.962305363655485	17.16546723977511
0.5	-2513.468860889121	21.290868096069055

Wnioski:

Drua tabela przedstawia średnie wartości dla uzyskanych x -ów i $f(x)$ -ów. Analizując ją można zauważyć, że nie daje ona zadowalających wyników. Aby pokazać, dlaczego tak jest, to dodatkowo ukazałem w pierwszej tabeli wyniki dla random seed-u=50. Jak możemy zauważyć, algorytm dla zakresu skoków 0.05 - 0.07 przyjmuje dobre wartości. Dla zakresu 0.001 - 0.03 prawie nie wychodzi z punktu startowego, a dla przedziału 0.1 - 0.5 wartości wystrzelują od minimum globalnego.

W tabeli ze średnimi można zauważyć częściowe pokrycie z przytoczonym przykładem, jednakże jest ono dalekie np. dla skoku 0.05. Z tego faktu wypływa natura SGD + momentum, to znaczy, że jakość danego skoku zależy po części od wygenerowanych

szumów. Dla przedziału 0.05 - 0.1 jest zauważalne zbliżenie do minimum globalnego, czyli że średnio dla wartości skoków z tego przedziału uzyskuje się dobre wyniki przeszukiwania.

Wyniki eksperymentów dla dwuwymiarowej funkcji Ackleya; SGD + Momentum

SKOK	X, Y	F(X, Y)	ITERACJE
0.001	(4.989893, 4.989189)	12.632872	17
0.01	(4.990577, 4.990986)	12.633391	37
0.03	(4.989987, 4.994452)	12.634466	19
0.05	(4.989575, 4.989226)	12.632818	651
0.07	(5.046701, 4.908011)	12.874767	1000
0.1	(2.982636, -2.342070)	9.769598	1000
0.15	(0.617655, 0.443188)	4.324331	1000
0.2	(-1.450333, 2.552555)	9.126751	1000
0.5	(-116.528554, -21.725219)	22.152479	1000

SKOK	Avg (X,Y)	Avg F(X, Y)
0.001	(4.98979963576935, 4.9899737936901385)	12.633001896477467
0.01	(4.990456433895501, 4.991088186079601)	12.633400312253684
0.03	(4.990389713949732, 4.991100095039759)	12.633507943841641
0.05	(4.991512328558487, 4.99011469206028)	12.633702772822588
0.07	(5.025410047786128, 4.947780030805994)	12.844394884580646
0.1	(-4.450730408675989, -3.1420647951967955)	12.453725145197705
0.15	(2.4794173004869053, 3.8323468811995363)	11.979013562285756
0.2	(-18.055008123329717, -26.165184632565428)	15.92318094728471
0.5	(35.812661006323125, 7.392852725361456)	21.96999947746779

Wnioski:

Podobnie jak dla funkcji jednowymiarowej, tutaj też występuje zależność między średnimi a poszczególnymi przykładami. Tu dla analizy też wziąłem przypadek dla random seed-u=50. Akurat dla funkcji dwuwymiarowej najlepsze wyniki przeszukiwań są dla skoków z przedziału 0.1 - 0.15. Dla przedziałów od 0.001 - 0.07 algorytm nie wychodzi z punktu startowego, a dla wartości większych od 0.2 - wędruje po funkcji.

Podsumowanie

Jak możemy zauważyć, algorytm gradientu prostego jak i SGD + Momentum jest bardzo wrażliwy na wartość skoku. Zbyt mała wartość spowoduje utknięcie algorytmu w punkcie startowym. Natomiast zbyt duża wartość spowoduje wędrowanie algorytmu po funkcji i zagnieżdżenia się w minimum lokalnym bez możliwości wyjścia z niego.

W przypadku różnic między algorytmem gradientu prostego, a SGD + Momentum zauważyłem tylko to, że ten drugi jest bardziej wrażliwy na wartość skoków niż ten pierwszy. Jest to cena za bardziej stabilny algorytm, gdyż rozwiązanie SGD + Momentum z dobrym skokiem gwarantuje mniejsze oscylacje w okolicach minimum globalnego, co za tym idzie zmniejsza szanse na 'wypadnięcie' algorytmu z dobrego dołka.