

Modele bayesowskie

WSI – ćwiczenie 7

Autor: Kacper Skrodzki

Wprowadzenie do eksperymentów


W ramach 7 ćwiczenia należało zaimplementować naiwny klasyfikator Bayesa i przetestować jego działanie dla zbioru SMS-ów posegregowanych na spam i ham (normalne wiadomości). Dodatkowo umożliwiłem podejrzenie top 10 słów pojawiających się w spamie jak i w hamie, oraz wprowadziłem możliwość tokenizacji unigramowej lub unigramowej+bigramowej.

Eksperymenty – unigram oraz unigram+bigram


W czasie eksperymentów skupiłem się na zbadaniu jak czynnik alpha – wygładzenie Laplace'a, wpływa na dokładność filtracji wiadomości SMS. Dodatkowo uwzględniłem różne wartości random seedów, aby nie pracować na tych samych zbiorach treningowych i walidacyjnych. Na wykresach są przedstawione uśrednione wyniki.

Przetestowane wartości alpha: [0.6, 0.7, 0.8, 0.9, 1.0]

Zakres random seedów: [30, 37, 45, 56, 68]



Wykres 1- średnia jakość walidacji do współczynnika alfa dla unigramu



Wykres 2 - średnia jakość walidacji do współczynnika alfa dla unigram+bigram

```

===== Używany seed: 68 =====
===== TOP 10 NAJWAŻNIEJSZYCH SŁÓW =====

Klasa: HAM
1. i, p-ństwo: (0.0277)
2. you, p-ństwo: (0.0227)
3. to, p-ństwo: (0.0193)
4. the, p-ństwo: (0.0137)
5. a, p-ństwo: (0.0131)
6. u, p-ństwo: (0.0117)
7. and, p-ństwo: (0.0107)
8. my, p-ństwo: (0.0101)
9. in, p-ństwo: (0.0100)
10. is, p-ństwo: (0.0092)

Klasa: SPAM
1. to, p-ństwo: (0.0234)
2. a, p-ństwo: (0.0121)
3. call, p-ństwo: (0.0112)
4. you, p-ństwo: (0.0096)
5. your, p-ństwo: (0.0085)
6. free, p-ństwo: (0.0077)
7. the, p-ństwo: (0.0068)
8. for, p-ństwo: (0.0066)
9. now, p-ństwo: (0.0064)
10. or, p-ństwo: (0.0059)

```

Rysunek 1 - top 10 słów dla SPAM i HAM dla zbioru testowego; seed=68; alpha=1.0

Zbiór testowy (alpha = 1.0) ---- Średnia dokładność: 0.984211

Wnioski

Jak można zauważyć na powyższych wykresach, pomimo prostoty algorytmu (założenie, że każde słowo jest niezależne od innych słów) są osiągnane bardzo dobre wyniki dokładności klasyfikacji. Najlepsze wyniki uzyskuje się dla współczynnika **alpha równego 1.0**.

Użycie unigram+bigram w stopniu marginalnym zmniejszyło dokładność klasyfikacji. Wynika to z faktu, że dodatkowe tokeny składające się z dwóch słów mogą wprowadzić niepotrzebne szumy w obliczeniach.

Lista top 10 słów występujących w SPAMie i w HAMie jest nie przypadkowo. W obu typach wiadomości często się pojawiają podstawowe słowa z języka angielskiego: **'a', 'the', 'to'**, lecz widać ewidentną różnicę w doborze słów. Wiadomości HAM zawierają często pierwszą i drugą osobę l.p.: **'I', 'you'**. Za to SPAM częściej zawiera tylko **'you'** oraz ma kluczowe słowa typowe dla różnych przekrętów: **'call', 'free'**.

Podsumowanie

Algorytm pomimo swojej prostoty, osiąga bardzo dobre wyniki. Dokładność na poziomie około 97% pozwala na dobrą filtrację spamu. Jednakże w rozwiązaniach komercyjnych (np. filter spamu w Gmail) potrzebna jest prawie, że 100% trafność klasyfikacji, gdyż z punktu widzenia konsumenta, nawet jedna źle sklasyfikowana wiadomość jest niezadowolającym wynikiem, gdyż może ona być bardzo ważna.